BÁO CÁO TIẾN ĐỘ TUẦN 3

Trọng tâm: tiền xử lý dữ liệu, xây dựng heterogeneous graph và chuẩn hóa dữ liệu hệ thống

1. Mục tiêu tuần

- Tiền xử lý và chuẩn hóa dữ liệu.

- Xây dựng đồ thị Drug - Protein - Disease.

- Thiết kế cơ sở dữ liệu hệ thống.

2. Công việc đã thực hiện

- Hoàn thiện module src/preprocess.py để làm sạch feature matrix, thay thế giá trị không hữu hạn, hỗ trợ các chế độ chuẩn hóa none/zscore/l2, khử trùng lặp cạnh và kiểm tra tính nhất quán của dữ liệu sau tiền xử lý.

- Xây dựng các bước kiểm chứng auxiliary exports gồm adj.csv, Allnode/AllNode.csv và Alledge.csv để phát hiện sai lệch giữa dữ liệu phụ trợ và edge list chuẩn trong dự án.

- Hoàn thiện module src/split.py cho negative sampling, stratified train/val/test split theo tỷ lệ 70/15/15, kiểm tra không chồng lấn giữa các tập và đảm bảo train graph chỉ dùng positive edges của tập train.

- Hoàn thiện module src/graph_builder.py để tạo PyG HeteroData cho ba loại nút drug, disease, protein; đồng thời sinh các cạnh thuận/ngược cho ba quan hệ chính drug-disease, drug-protein và protein-disease.

- Thiết kế lớp dữ liệu phục vụ hệ thống ở mức artifact/lookup thông qua src/feature_builder.py và bộ JSON export trong results/web_export_smoke/ nhằm chuẩn bị cho lớp web tra cứu.

3. Kết quả đạt được

- Dữ liệu C-dataset được kiểm tra hợp lệ với các cảnh báo quan trọng đã được ghi nhận rõ: adj.csv lệch 1 liên kết so với edge list chuẩn (2531 so với 2532) và Alledge.csv chứa 144 cạnh trùng lặp. Hệ thống chọn edge list chuẩn làm nguồn chân lý.

- Bộ split cho C-dataset được tạo ổn định với 2532 positive pairs, 2532 negative pairs, 3544 mẫu train, 760 mẫu validation và 760 mẫu test.

- Đồ thị train heterograph được dựng đúng với các cạnh message passing chính; báo cáo graph cho thấy training graph còn một số nút cô lập (drug=4, disease=26), trong khi full graph cho inference không còn nút cô lập.

- Tầng dữ liệu phục vụ hệ thống đã có cấu trúc rõ ràng: metadata.json, drug_lookup.json, disease_lookup.json, protein_lookup.json, giúp giai đoạn sau có thể truy vấn tên thuốc/bệnh/protein thuận tiện hơn.

- Nội dung "thiết kế cơ sở dữ liệu hệ thống" ở giai đoạn hiện tại được triển khai theo hướng dữ liệu có cấu trúc và artifact quản lý; phần database quan hệ cho website mới dừng ở mức phác thảo trong tài liệu kế hoạch.

4. Minh chứng theo mã nguồn và artifacts

- src/preprocess.py: xử lý làm sạch và validate dữ liệu đầu vào.

- src/split.py: negative sampling, stratified split và các kiểm tra tránh leakage.

- src/graph_builder.py: xây dựng HeteroData và graph report cho PyG.

- src/feature_builder.py: tạo feature bundle, lookup table và export node tables cho web.

- results/baseline.json và results/web_export_smoke/metadata.json: thể hiện rõ thống kê split/graph và bộ artifacts xuất ra cho hệ thống.

5. Khó khăn và hướng xử lý

- Dữ liệu phụ trợ trong benchmark không hoàn toàn sạch, thể hiện qua lệch đếm ở adj.csv và cạnh trùng trong Alledge.csv. Hướng xử lý là thêm bước validate tự động và ưu tiên edge list canonical.

- Việc dựng train graph phải bảo đảm không đưa positive edges của validation/test vào message passing. Hướng xử lý là tách riêng build_train_graph_edges trong src/split.py và dùng graph mode train/full rõ ràng.

6. Kế hoạch tuần tiếp theo

- Thiết kế và cài đặt mô hình HGT.

- Xây dựng pipeline huấn luyện và dự đoán hoàn chỉnh.

- Kiểm thử mô hình ban đầu, so sánh baseline và HGT, đồng thời chuẩn bị dashboard demo.