BÁO CÁO TIẾN ĐỘ TUẦN 4

Trọng tâm: cài đặt HGT, hoàn thiện pipeline train/inference và kiểm thử mô hình ban đầu

1. Mục tiêu tuần

- Thiết kế và cài đặt mô hình HGT.

- Xây dựng pipeline huấn luyện và dự đoán.

- Kiểm thử mô hình ban đầu.

2. Công việc đã thực hiện

- Hoàn thiện baseline MLP trong src/baseline.py để tạo mốc so sánh tối thiểu cho bài toán link prediction Drug-Disease.

- Cài đặt mô hình chính trong src/model_hgt.py bằng HGTConv của PyG: có projection riêng cho drug/disease/protein, nhiều lớp HGT, residual connection, layer norm và decoder ở các chế độ product/concat/hybrid.

- Hoàn thiện src/trainer.py và src/evaluator.py với BCEWithLogitsLoss, focal loss, early stopping theo validation AUPR, checkpointing và bộ metric AUC/AUPR/Accuracy/Precision/Recall/F1/MCC.

- Mở rộng src/main.py để huấn luyện baseline/HGT qua CLI; bổ sung các siêu tham số như hidden_dim, số layer, số head, hard_negative_ratio, decoder mode và loại loss.

- Xây dựng src/inference.py cho suy luận top-k theo tên thuốc hoặc chỉ số, score toàn bộ disease candidates, lọc liên kết đã biết và export bộ metadata/lookup cho web.

- Viết src/hparam_search.py để random search trên 20 cấu hình Tier-1, tự lưu checkpoint và search_summary.json.

- Hoàn thiện dashboard/app.py bằng Streamlit tiếng Việt để xem tổng quan training, chọn checkpoint, tìm thuốc theo tên/DrugBank ID, xem known associations, dự đoán top-k và tải CSV xác minh.

3. Kết quả kiểm thử và đánh giá ban đầu

- Baseline MLP trên C-dataset đạt test AUPR xấp xỉ 0.5625 và test AUC xấp xỉ 0.5621; đây là mốc tham chiếu ban đầu cho bài toán.

- Cấu hình HGT Tier-1 seed42 đạt best validation AUPR khoảng 0.6235, test AUPR khoảng 0.5713, test F1 khoảng 0.6160; cho thấy HGT bước đầu hoạt động ổn định và có cải thiện nhẹ so với baseline cơ bản.

- Kết quả random search 20 trial cho thấy tiềm năng cải thiện đáng kể: trial 008 đạt validation AUPR khoảng 0.7273 và test AUPR khoảng 0.6901; một cấu hình khác (trial 015) đạt test AUPR khoảng 0.7118.

- Inference smoke test đã chạy thành công với checkpoint HGT, ví dụ truy vấn thuốc Goserelin có thể sinh top-5 bệnh ứng viên mới; đồng thời hệ thống đã export đầy đủ metadata và lookup JSON cho lớp web.

- Dashboard tiếng Việt đã có thể dùng để demo trực quan kết quả huấn luyện và truy vấn dự đoán theo tên thuốc, phù hợp cho giai đoạn báo cáo/thuyết trình.

4. Minh chứng theo mã nguồn và kết quả chạy thật

- src/model_hgt.py: cài đặt kiến trúc HGT cho heterogeneous graph.

- src/trainer.py và src/evaluator.py: cài đặt huấn luyện, early stopping và đánh giá metric.

- src/inference.py và src/hparam_search.py: suy luận top-k và random search siêu tham số.

- dashboard/app.py: giao diện trực quan cho demo kết quả.

- results/hgt_tier1_seed42.json, results/hgt_tier1.json, results/hgt_inference_smoke_topk.json và results/tier1_search_20/search_summary.json: minh chứng số liệu huấn luyện, suy luận và tìm kiếm cấu hình.

- agent/worklog_2026-04-07.md: nhật ký kỹ thuật ghi lại các cập nhật chính trong ngày hoàn thiện Tier-1 và dashboard.

5. Khó khăn và hướng xử lý

- Một số checkpoint cũ dùng khóa cấu hình hidden_dims thay vì hidden_dim, gây lỗi load model. Hướng xử lý là bổ sung backward compatibility trong src/inference.py.

- Mô hình HGT ban đầu còn nhạy với cấu hình decoder, loss và hard negatives. Hướng xử lý là dùng random search, multi-seed benchmark và chọn best model theo validation AUPR thay vì test set.

- Dashboard cần giữ cân bằng giữa tính trực quan và tính học thuật. Hướng xử lý là hiển thị rõ bệnh đã biết, bệnh dự đoán mới và cảnh báo cần xác minh ngoài benchmark.

6. Hướng phát triển tiếp theo

- Chạy benchmark nhiều seed để đánh giá độ ổn định của mô hình.

- Chuẩn hóa báo cáo kết quả baseline vs HGT bằng bảng và hình cho phần thuyết trình.

- Bổ sung giải thích đường đi Drug -> Protein -> Disease hoặc case study cụ thể để tăng tính giải thích của mô hình.

- Xem xét mở rộng Tier-2 theo hướng similarity branch/AMDGT-lite sau khi lõi HGT hiện tại đã ổn định.